

Sistema de Consolidación de Ventas Omnicanal Super-Market

Workshop de Data Engineering - Pitch Técnico

Geraldine Cornejo, Javiera Barrales, Rodrigo Flores

Junio 2026

Universidad Técnica Federico Santa María

- **Silos Transaccionales:** Las sucursales generan ventas y logs en sistemas desconectados geográficamente.
- **Anomalías Financieras:** Ruido en la data como montos negativos, en cero, o nulos, que rompen analíticas (`amount <= 0`).
- **Disparidad Cambiaria:** Operaciones mezcladas en monedas locales que dificultan la consolidación de reportes corporativos globales.

Visión General de la Arquitectura



Fase 1: Ingesta Paralela (Apache Beam)

- **Escalabilidad Horizontal:** I/O optimizado superando cuellos de botella mediante hilos.
- **Resiliencia:** Aislamiento de errores financieros a través de Side Outputs, evitando que el flujo principal se detenga.

Código: Ingesta Paralela

```
class ParallelCSVReaderFn(beam.DoFn):
    def process(self, file_path: str) -> Iterable[str]:
        file_queue: Queue = Queue()
        results: Queue = Queue()
        lock = threading.Lock()

        def worker() -> None:
            while not file_queue.empty():
                with lock: # Bloqueo seguro para multihilo
                    if file_queue.empty(): break
                    line = file_queue.get()
                results.put(line)
```

- **Sinking Strategy:** Uso de Parquet para almacenamiento columnar eficiente, ideal para Big Data.
- **Contrato Fuerte:** PyArrow garantiza matemáticamente la estructura anidada de los registros antes de ser persistidos.

Código: Contrato PyArrow

```
SILVER_SCHEMA = pa.schema([
    ('id', pa.string()),
    ('store', pa.string()),
    ('financials', pa.struct([
        ('raw_amount', pa.float64()),
        ('currency', pa.string())
    ])),
    ('status_history', pa.list_(pa.struct([
        ('status', pa.string()),
        ('date', pa.timestamp('us'))
    ])))
])
```

Fase 2: Modelado Analítico (dbt)

- **Business Value:** Generación de KPIs financieros (e.g., `amount_usd`, `is_active`).
- **Data Quality:** Expectativas matemáticas rigurosas desde la base de datos (no-nulos, unicidad, límites numéricos).

Código: dbt Expectations

```
models:
  - name: fct_sales
    columns:
      - name: transaction_id
        tests:
          - unique
          - not_null
      - name: amount_usd
        tests:
          - dbt_expectations.expect_column_values_to_be_between:
              min_value: 0.01
```

Orquestación y Resiliencia (Apache Airflow)

- **Circuit Breaker Estricto:** Dependencias lineales que protegen la Capa Gold.
- **Validación asíncrona:** FileSensor detiene el pipeline si la Capa Silver falla o tarda demasiado.



Código: Airflow FileSensor

```
sensor_silver_data = FileSensor(  
    task_id='sensor_silver_data',  
    filepath=silver_layer_path,  
    fs_conn_id='fs_default',  
    poke_interval=30,  
    timeout=600 # Falla automatica despues de 10 min  
)
```

Las 4 Preguntas de Beam

- **What are you computing?** Limpieza de anomalías y unión transaccional (ventas e historiales).
- **Where in event time?** Ventanas Globales (Global Windows), procesando en lotes acotados.
- **When in processing time?** Orquestado al finalizar el día de operaciones (Batch end-of-day trigger).
- **How do refinements relate?** CoGroupByKey para iterar y agrupar flujos inconexos y anidarlos en arrays estructurales.